

汽车垂直领域 RAG 知识库构建方案

从文件导入到可溯源问答的数据工程方案

文档属性	内容
项目	汽车直播智能体
版本	v1.2
编制日期	2026 年 8 月
适用范围	竞赛答辩、技术评审、现场演示

方案结论 RAG 的核心不是堆叠模型，而是把车型资料变成可定位、可版本化、可拒答的证据单元。系统优先输出资料中能直接找到的参数，无法确认时明确标注置信度。

1 场景与问题定义

汽车直播资料同时存在 PDF 配置表、Word 话术和 TXT 参数清单，格式不一、字段命名不一、版本更新频繁。传统全文搜索难以回答“续航是多少”这类短问题，也无法告诉主播答案来自哪一页、哪一版。方案将资料拆成可检索的证据片段，并在回答中保留来源。

2 数据处理链路

- 上传与登记：计算文件哈希，登记文件类型、车型元数据、导入时间和版本号。
- 解析与清洗：PDF 按页提取，DOCX 同时读取段落和表格，TXT 保留原始行序；统一空白、全角符号和异常换行。
- 分段与结构化：优先按标题、字段名、句号和长度切分；识别品牌、车系、年款、参数名和值。
- 索引与入库：保存片段文本、来源文档、页码、版本、词法索引和稳定哈希向量。
- 检索与回答：对问题做字段归一化和词法扩展，按混合得分排序；答案携带 confidence 和 sources。

处理阶段	输入	输出	质量门
解析	PDF/DOCX/TXT	纯文本 + 位置	文件可读、页码可追踪
清洗	混合文本	规范化文本	空白与异常符号受控
切分	规范化文本	证据片段	片段长度可检索
结构化	片段	字段 + 元数据	车型和版本不丢失
检索	问题	候选片段	来源可回溯

3 检索策略

系统采用可复现的混合检索：第一路是字段名、车型名、数字单位等词法命中；第二路是稳定哈希向量相似度，用于处理近义表达；最终分数综合两路结果并对同一文档相邻片段做轻量合并。对“续航、轴距、最大功率”等高价值字段设置优先级，减少无关描述抢占结果。

拒答规则 候选片段不足、版本冲突或字段没有证据时，不生成看似完整的答案；返回“当前资料未确认”并保留检索结果，避免直播间出现不可追溯的参数。

4 版本、溯源与管理

能力	实现	主播可见结果
增删改查	文档、片段和版本独立记录	能替换资料并查看当前版本
版本管理	文件哈希 + version_no + imported_at	回答标注资料版本
检索溯源	document_id、document_name、page、score	答案下方展示来源片段
批量处理	一次提交多个文件，逐项返回状态	成功、失败和原因可区分

5 测试设计与结果

测试集覆盖续航、动力、车身尺寸、安全配置、补能、智能驾驶和购车政策等问题；每条样本包含问题、期望字段或证据、实际答案和来源。当前检索测试 40/40，最终问答测试 40/40，平均检索延迟约 8 ms，达到题目要求。

测试项	样本量	通过	准确率/延迟
字段检索	40	40	100%，平均 7.9 ms
最终问答	40	40	100%，平均 8.1 ms
批量导入	2 文件	2	TXT + 车型参数 TXT
版本查询	1 文档	1	可返回历史版本

6 现场演示脚本

- 导入一份车型 TXT，再导入一份 Word 或 PDF，展示片段数量、车型元数据和版本。
- 提问“欧拉 5 EV 的续航是多少”，展示答案、置信度、来源文档和片段。
- 替换参数文档后再次提问，展示版本变化和来源更新。
- 在验证页打开 40 条测试结果，说明指标如何对应题目要求。

参考资料

- GPT-SoVITS 官方中文说明：<https://github.com/RVC-Boss/GPT-SoVITS/blob/main/docs/cn/README.md>

- 参赛题目文件：C:/Users/seele/Desktop/6.（海云捷迅）2026 年第二届重庆市 AI 大模型创新应用大赛企业出题.docx